RETO DE INGRESO · IMPLEMENTADOR DE AGENTES IA · METEOR

Donde Toño: decisiones, pruebas y limitaciones

Jhon Escobar · 22 de octubre de 2026

AGENTE

Lau, en **Conversación de prueba** del workspace "Donde Toño - Jhon Escobar". El correo de registro va en el mensaje de entrega.

PRUEBAS

Colección **Evals** (una fila por escenario) y el repositorio con spec, código y evidencia. Diagrama de arquitectura adjunto.

REGISTRO DE PEDIDOS

Pedidos: donde caen los reales (hoy trae 4 ejemplos marcados como ficticios). **Pedidos de prueba**: los 19 de mis pruebas, aparte para no ensuciar producción.

TIEMPO

Unas **7 h 45** de trabajo activo: lunes 2 h 15 (1 h 30 de ellas aprendiendo la plataforma), martes 2 h 45 y miércoles 2 h 45.

01 Cómo está armado

Lau conversa y entiende el pedido, pero **no suma**. El total, el domicilio y el tiempo los calcula la Función `cotizar_pedido`: un flujo de Meteor que lee el Menú, las Adiciones y las Zonas y hace la cuenta en JavaScript, igual cada vez. `crear_pedido` solo funciona si se cotizó en el mismo turno, y copia el resultado del cálculo, no lo que escribió el modelo. Cada dato vive en un solo lugar: precios y disponibilidad en las colecciones, el horario en el horario nativo y las reglas de conversación en las instrucciones de Lau. Así un cambio en vivo (un precio, un producto agotado, una zona) es editar una fila.

02 Supuestos

- **Salchipapa especial sin queso gratinado: $22.000.** Meteor confirmó que el perro especial mantiene su precio; por la salchipapa no respondió.
- **El mínimo de $15.000** es sobre los productos, sin contar el domicilio.
- **Tiempo del pedido** = el producto más demorado + el trayecto de la zona. Los trayectos son los de un viernes en la noche, así que entre semana el pedido llega antes de lo prometido, nunca después.
- **"Para cuándo"** es siempre "lo antes posible": no hay pedidos programados.
- **Cerveza "solo en el local"**: no entra ni a domicilio ni para recoger, porque los dos son para llevar.
- **"Queso gratinado" agotado** aplica a todo producto que lo lleve (perro y salchipapa especial): se vende sin él y se le avisa al cliente. "Queso" a secas es el tajado, que sí hay.
- **Salsa de ajo "para todos"** = toda la comida, no las bebidas.
- **Almuerzo del día**: se vende como "sopa y seco del día"; el detalle lo confirma cocina.
- **La frase fija del chat de prueba** (ver 05) es del canal y no de Lau: el pedido sí queda registrado.

03 Preguntas a Toño

Antes de construir. De 20 preguntas posibles envié 10: solo las que cambian un precio, un total o lo que se puede vender y que la hoja no responde. Cada una llevaba entre paréntesis el supuesto que usaría si no respondía, para no frenar el trabajo. Las respuestas quedaron como reglas citadas: la clásica de $18.000 sobraba y el combo lleva la de brioche; el combo acepta adiciones; la picada familiar vale $45.000; el chorizo aplica a salchipapas y picadas; solo falta el queso gratinado y el aguacate como adición; tiempos de domicilio por zona; un barrio que no está en la lista no se asume; el Centro cuesta $6.000 y 25 min; los festivos usan el horario del domingo aunque caigan lunes; con el local cerrado solo se informa el horario.

Seguimiento. ¿Los productos sin queso gratinado mantienen su precio? (perro sí; salchipapa sin respuesta, queda como supuesto) y ¿la bandeja paisa es de 2 o de 20 min? (20). Quedó anotada una contradicción: la respuesta dice que los tiempos de domicilio están "en la hoja", y la hoja no los trae; se tomaron de la respuesta.

Lo que le preguntaría ahora, ya con el agente funcionando:

- ¿Cuántos pedidos entran un viernes en la noche y cuántos se pierden? Es la línea base para medir si el agente sirve.
- ¿Quién del equipo atiende cuando Lau pasa una queja o un pedido grande, en cuánto tiempo y en qué horario?
- ¿Cómo quiere enterarse de un pedido nuevo: mirando la colección desde el celular o con un aviso a cocina?

04 Qué quedó por fuera y por qué

- **Pagos en línea, POS, facturación, app o web e impresora de comandas:** fuera de alcance según el reto.
- **Cobrar o validar transferencias:** la hoja dice que se paga "al recibir"; Lau solo registra cómo va a pagar.
- **Pedidos anticipados:** Toño respondió que no se toman.

- **Tiempo según la carga de la cocina:** Toño dijo que todo se prepara en paralelo y que los tiempos ya son los de un viernes; no hay datos de carga. Mejora: un campo de "demora actual" que Toño suba en hora pico.
- **Apagar productos por insumo y menú diario del almuerzo:** dependen de que alguien actualice algo cada día. Hoy la columna Disponible es la fuente de verdad. Mejora: cargar el almuerzo cada mañana.
- **Dashboard, CRM aparte o tablero Kanban:** el reto acepta una colección o vista, y lo nativo de Meteor alcanza. El Kanban por estado queda como mejora.
- **WhatsApp y widget web (dónde me topé con la plataforma):** no hubo número de pruebas y conectar uno propio no hacía falta, porque el reto acepta el chat del workspace. El widget no aparece solo en un sitio de Sitios Web y su enlace público no está documentado; lo dejé tras un intento con tiempo acotado.
- **Funciones y colecciones solo para pruebas** (o un workspace de staging): mejora para producción. Hoy las pruebas pasan por el `crear_pedido` real, que es lo que hay que probar, y un script mueve cada pedido de prueba a su colección.
- **Sin probar:** el cruce de medianoche (un viernes a las 00:45 sigue abierto el turno del viernes); el E15 a mano, que ya pasó por API; y confirmar la causa de la frase fija (ver 05), por energía, porque exigía exponerle Pedidos al modelo y porque no cambia la entrega.

05 Qué sé que puede fallar

- **En el chat de prueba, todo pedido termina con una frase fija:** "No pude verificar el estado del pedido. Necesitamos revisar el registro existente…". El pedido **sí queda registrado** con todos sus datos, pero el cliente podría volver a pedir. Por API, Lau confirmó con el número en 11 de 11 registros. Descarté el prompt (la regla prohíbe la frase y sale igual), el formato del resultado (un JSON con `ok: true` da lo mismo) y la visibilidad de la colección. Hipótesis sin probar: el canal intenta verificar lo que escribió la Función y no puede, porque Pedidos está oculta al modelo. Si se confirma, el arreglo es una Función `consultar_pedido(numero)` que devuelva solo ese pedido.
- **Energía:** una conversación con pedido cuesta cerca de US$0,30 y al entregar quedan unos US$0,70. Si se acaba, Lau deja de responder y parece caído.
- **Un solo contacto de prueba compartido:** si dos personas prueban a la vez se mezclan las conversaciones, y resetear borra el historial. Tras pasar a una persona, Lau calla 2 min (en producción serían 5 h).
- **Narración:** a veces Lau comenta su proceso ("ya los verifiqué"). Se corrigió en las instrucciones y queda un caso aislado.
- **Cruce de medianoche** sin probar. Si falla, el corte de domicilios pasa al cálculo en JS.
- **El trial vence el lunes 26 de octubre.**

06 Cómo lo probé

- **El cálculo, aparte de la conversación:** 12 pedidos con total conocido y 12 rechazos (cerveza, máximo de adiciones, zona, mínimo), contra totales calculados por un script independiente. 24 de 24, primero en local y después dentro de Meteor.
- **La conversación:** 24 escenarios escritos antes de construir (Dado / Cuando / Entonces). 20 por API, con `POST /runs`: checks automáticos (total, tiempo, Funciones llamadas, nada de inventos) y lectura de cada transcripción, porque los checks no vieron dos fallas reales. 4 a mano en el chat (corte de domicilios, almuerzo fuera de hora, queja y nota de voz) y el pedido base repetido en PC y celular.
- **Resultado en Evals:** 21 pasan, 3 pasan con observación (la narración, y dos pasos a una persona que por API no se pueden completar y el E19 sí probó a mano) y 1 limitación (la frase fija).
- **Fallas reales encontradas y corregidas:** el lunes festivo salía cerrado; a un cliente le llegó solo "Déjame verificar…" sin respuesta; en la primera prueba, asteriscos sin formato, una dirección sin calle y un registro rechazado por no cotizar en el mismo turno. Cada arreglo se volvió a probar.
- **Costo de las pruebas:** unos US$3,30 de energía el miércoles, medidos con el saldo antes y después.

07 Uso de la IA

Trabajé con Claude Code: escribió la mayor parte del código, los documentos y las llamadas a la API. Yo definí el alcance (mi primera pregunta fue si estábamos sobreconstruyendo), tomé las decisiones (el cálculo determinista, pasar a "una persona del equipo" y no a Toño, separar los pedidos de prueba, cuándo dejar de investigar) y probé a mano lo que la API no podía ver. Comparar los dos caminos, API y chat real, fue lo que encontró la limitación principal.